量化投资与Python

本节内容

- 怎样用Python做量化投资
- IPython命令行介绍
- Numpy模块介绍
- pandas模块介绍
- Matplotlib模块介绍

为什么选择Python?

- 其他选择：Excel、SAS/SPSS、R
- 量化投资实际上就是分析数据从而作出决策的过程。
- Python数据处理相关模块
  - NumPy：数组批量计算
  - pandas：灵活的表计算
  - Matplotlib：数据可视化

如何使用Python进行量化投资

- 自己编写：NumPy+pandas+Matplotlib+……
- 在线平台：聚宽、优矿、米筐、Quantopian、……
- 开源框架：RQAlpha、QUANTAXIS、……

IPython

交互式的Python命令行

IPython的安装与使用

- 安装： pip install ipython
- 使用： ipython
- 与Python解释器的使用方法一致

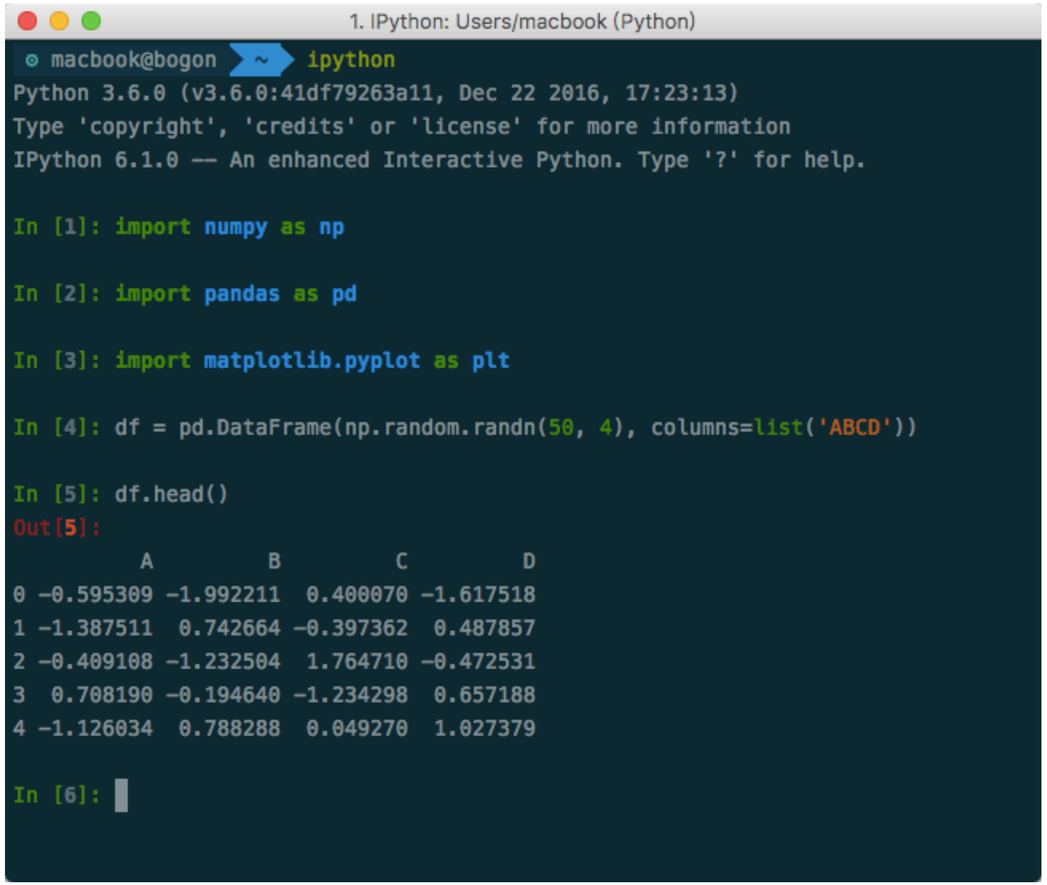

IPython高级功能

- TAB键自动完成
- ?：内省、命名空间搜索
- !：执行系统命令
- 丰富的快捷键

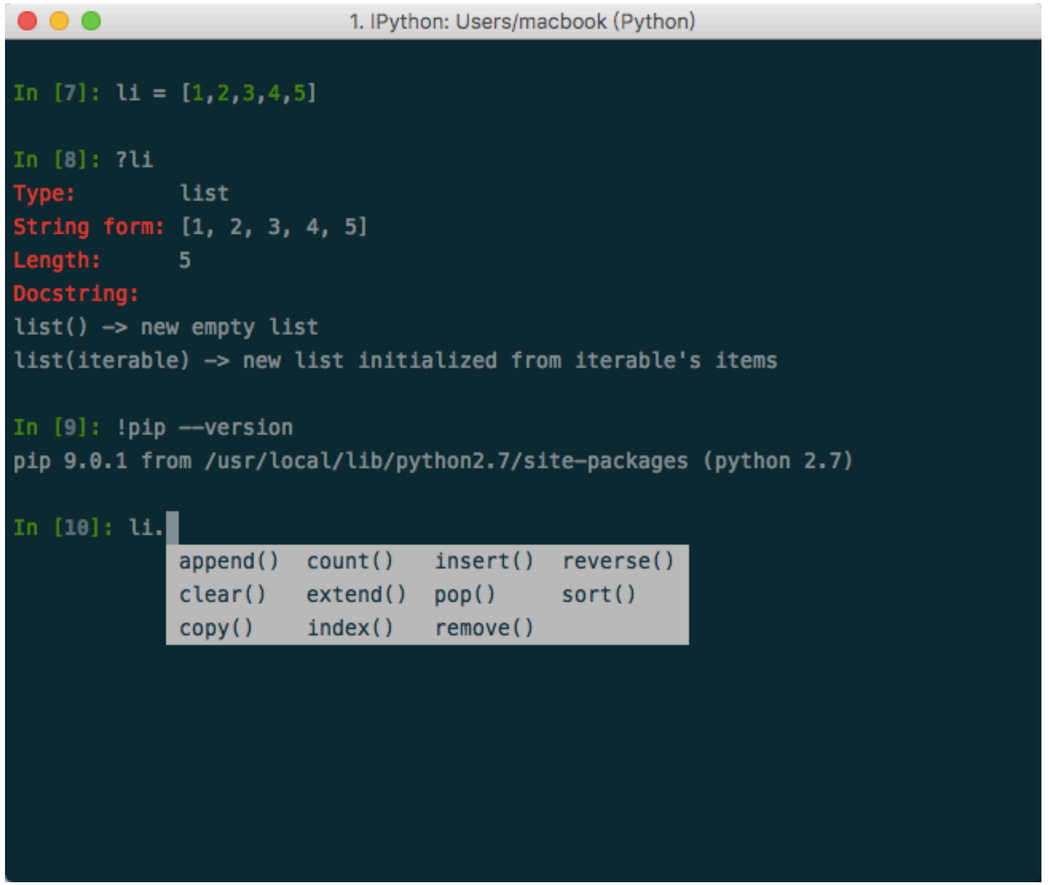

命令	说明
Ctrl-P或上箭头键	后向搜索命令历史中以当前输入的文本开头的命令
Ctrl-N或下箭头键	前向搜索命令历史中以当前输入的文本开头的命令
Ctrl-R	按行读取的反向历史搜索（部分匹配）
Ctrl-Shift-v	从剪贴板粘贴文本
Ctrl-C	中止当前正在执行的代码
Ctrl-A	将光标移动到行首
Ctrl-E	将光标移动到行尾
Ctrl-K	删除从光标开始至行尾的文本
Ctrl-U	清除当前行的所有文本[译注12]
Ctrl-F	将光标向前移动一个字符
Ctrl-b	将光标向后移动一个字符
Ctrl-L	清屏

IPython高级功能

- 魔术命令：以%开始的命令
  - %run：执行文件代码
  - %paste：执行剪贴板代码
  - %timeit：评估运行时间
  - %pdb：自动调试

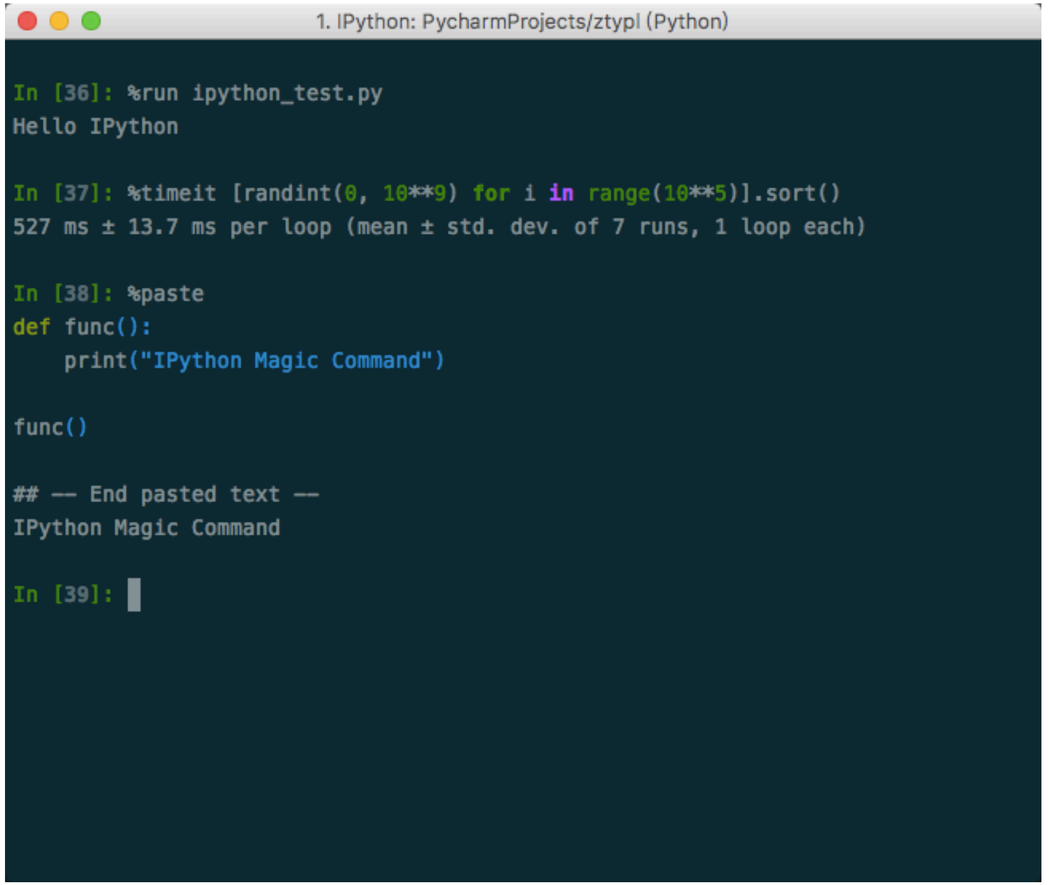

命令	说明
%quickref	显示IPython的快速参考
%magic	显示所有魔术命令的详细文档
%debug	从最新的异常跟踪的底部进入交互式调试器
%hist	打印命令的输入（可选输出）历史
%pdb	在异常发生后自动进入调试器
%paste	执行剪贴板中的Python代码
%cpaste	打开一个特殊提示符以便手工粘贴待执行的Python代码
%reset	删除interactive命名空间中的全部变量/名称
%page *OBJECT*	通过分页器打印输出OBJECT
%run *script.py*	在IPython中执行一个Python脚本文件
%prun *statement*	通过cProfile执行statement，并打印分析器的输出结果
%time *statement*	报告statement的执行时间
%timeit *statement*	多次执行statement以计算系综平均执行时间。对那些执行时间非常小的代码很有用
%who、%who_ls、%whos	显示interactive命名空间中定义的变量，信息级别/冗余度可变
%xdel *variable*	删除variable，并尝试清除其在IPython中的对象上的一切引用

命令	功能
h(elp)	显示命令列表
help *command*	显示*command*的文档
c(ontinue)	恢复程序的执行
q(uit)	退出调试器，不再执行任何代码
b(reak) *number*	在当前文件的第*number*行设置一个断点
b path/to/*file.py:number*	在指定文件的第*number*行设置一个断点
s(tep)	单步进入函数调用
n(ext)	执行当前行，并前进到当前级别的下一行
u(p)/d(own)	在函数调用栈中向上或向下移动
a(rgs)	显示当前函数的参数
debug *statement*	在新的（递归）调试器中调用语句*statement*
l(ist) *statement*	显示当前行，以及当前栈级别上的上下文参考代码
w(here)	打印当前位置的完整栈跟踪（包括上下文参考代码）

IPython高级功能

- 使用命令历史
- 获取输入输出结果
- 目录标签系统
- IPython Notebook

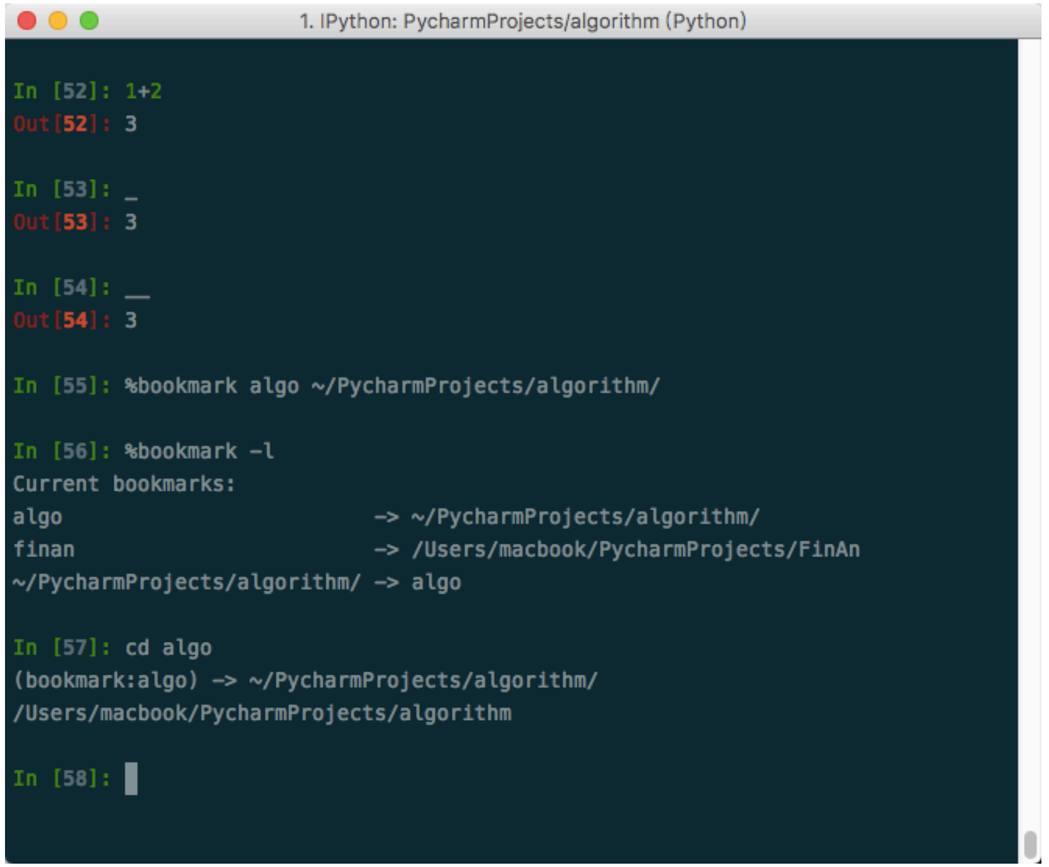

NumPy

数据分析基础包

NumPy简介

- NumPy是高性能科学计算和数据分析的基础包。它是pandas等其他各种工具的基础。
- NumPy的主要功能：
  - ndarray，一个多维数组结构，高效且节省空间
  - 无需循环对整组数据进行快速运算的数学函数
  - 线性代数、随机数生成和傅里叶变换功能
- 安装方法：pip install numpy
- 引用方式：import numpy as np

为什么要用NumPy?

- 例1：已知若干家跨国公司的市值（美元），将其换算为人民币
- 例2：已知购物车中每件商品的价格与商品件数，求总金额。

ndarray-多维数组对象

- 创建ndarray：np.array(array_like)
- 数组与列表的区别：
  - 数组对象内的元素类型必须相同
  - 数组大小不可修改

ndarray-常用属性

- T　　数组的转置（对高维数组而言）$\begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix} \Rightarrow \begin{pmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{pmatrix}$
- size　数组元素的个数
- ndim　数组的维数
- shape 数组的维度大小（元组形式）
- dtype 数组元素的数据类型

ndarray-数据类型

- 布尔型：bool_
- 整型：int_ int8 int16 int32 int64
- 无符号整型：uint8 uint16 uint32 uint64
- 浮点型：float_ float16 float32 float64
- 复数型：complex_ complex64 complex 128

ndarray-创建

- array()　　将列表转换为数组，可选择显式指定dtype
- arange()　　range的numpy版，支持浮点数
- linspace()　　类似arange()，第三个参数为数组长度
- zeros()　　根据指定形状和dtype创建全0数组
- ones()　　根据指定形状和dtype创建全1数组
- empty()　　根据指定形状和dtype创建空数组（随机值）
- eye()　　根据指定边长和dtype创建单位矩阵

ndarray-批量运算

- 数组和标量之间的运算
  - a+1　　a*3　　1//a　　a**0.5　　a>5
- 同样大小数组之间的运算
  - a+b　　a/b　　a**b　　a%b　　a==b

ndarray-索引

- 一维数组的索引：a[5]
- 多维数组的索引：
  - 列表式写法：a[2][3]
  - 新式写法：a[2,3]

ndarray-切片

- 一维数组的切片：a[5:8]　　a[4:]　　a[2:10] = 1
- 多维数组的切片：a[1:2, 3:4]　　a[:,3:5]　　a[:,1]
- 数组切片与列表切片的不同：数组切片时并不会自动复制（而是创建一个视图），在切片数组上的修改会影响原数组。
  - copy()方法可以创建数组的深拷贝

ndarray-布尔型索引

- 问题：给一个数组，选出数组中所有大于5的数。
  - 答案：a[a>5]
- 原理：
  - **数组与标量的运算**：a>5会对a中的每一个元素进行判断，返回一个布尔数组
  - **布尔型索引**：将同样大小的布尔数组传进索引，会返回一个由所有True对应位置的元素的数组

ndarray-布尔型索引

- 问题2：给一个数组，选出数组中所有大于5的偶数。
  - 答案：a[(a>5) & (a%2==0)]
- 问题3：给一个数组，选出数组中所有大于5的数和偶数。
  - 答案：a[(a>5) | (a%2==0)]

ndarray-花式索引

- 问题1：对于一个数组，选出其第1，3，4，6，7个元素，组成新的二维数组。
  - 答案：a[[1,3,4,6,7]]
- 问题2：对一个二维数组，选出其第一列和第三列，组成新的二维数组。
  - 答案：a[:,[1,3]]

NumPy-通用函数

- 通用函数：能同时对数组中所有元素进行运算的函数
- 常见通用函数：
  - 一元函数：**abs**, **sqrt**, exp, log, **ceil**, **floor**, **rint**, **trunc**, **modf**, **isnan**, **isinf**, cos, sin, tan
  - 二元函数：add, substract, multiply, divide, power, mod, **maximum**, **mininum**,

补充-浮点数特殊值

- nan(Not a Number)：不等于任何浮点数（nan != nan)
- inf(infinity)：比任何浮点数都大
- NumPy中创建特殊值：np.nan　　np.inf
- 在数据分析中，nan常被用作表示数据缺失值

NumPy-数学和统计方法

- sum 求和
- mean 求平均数
- std 求标准差
- var 求方差
- min 求最小值
- max 求最大值
- argmin 求最小值索引
- argmax 求最大值索引

NumPy-随机数生成

- 随机数函数在np.random子包内
  - rand　　给定形状产生随机数组（0到1之间的数）
  - randint　　给定形状产生随机整数
  - choice　　给定形状产生随机选择
  - shuffle　　与random.shuffle相同
  - uniform　　给定形状产生随机数组

pandas

数据分析核心工具包

pandas简介

- pandas是一个强大的Python数据分析的工具包，是基于NumPy构建的。
- pandas的主要功能
  - 具备对其功能的数据结构DataFrame、Series
  - 集成时间序列功能
  - 提供丰富的数学运算和操作
  - 灵活处理缺失数据
- 安装方法：pip install pandas
- 引用方法：import pandas as pd

Series-一维数据对象

- Series是一种类似于一位数组的对象，由一组数据和一组与之相关的数据标签（索引）组成。
- 创建方式：pd.Series([4,7,-5,3])
  pd.Series([4,7,-5,3],index=['a','b','c','d'])
  pd.Series({'a':1, 'b':2})
  pd.Series(0, index=['a','b','c','d'])
- 获取值数组和索引数组：values属性和index属性
- Series比较像列表（数组）和字典的结合体

```
In [81]: pd.Series([4,7,-5,3],index=['a','b','c','d'])
Out[81]:
a    4
b    7
c   -5
d    3
dtype: int64
```

Series-使用特性

- Series支持array的特性（下标）：
  - 从ndarray创建Series：Series(arr)
  - 与标量运算：sr*2
  - 两个Series运算：sr1+sr2
  - 索引：sr[0], sr[[1,2,4]]
  - 切片：sr[0:2]
  - 通用函数：np.abs(sr)
  - 布尔值过滤：sr[sr>0]
- Series支持字典的特性（标签）：
  - 从字典创建Series：Series(dic),
  - in运算：’a’ in sr
  - 键索引：sr['a'], sr[['a', 'b', ‘d']]

Series-整数索引

- 整数索引的pandas对象往往会使新手抓狂。
- 例：
  - sr = pd.Series(np.arange(4.))
  - sr[-1]
- 如果索引是整数类型，则根据整数进行下标获取值时总是面向标签的。
- 解决方法：**loc**属性（将索引解释为标签）和**iloc**属性（将索引解释为下标）

Series-数据对齐

- 例：
  - sr1 = pd.Series([12,23,34], index=['c','a','d'])
  - sr2 = pd.Series([11,20,10], index=[‘d','c','a'])
  - sr1+sr2

- pandas在进行两个Series对象的运算时，会按索引进行对齐然后计算。

Series-数据对齐

- 例：
  - sr1 = pd.Series([12,23,34], index=['c','a','d'])
  - sr2 = pd.Series([11,20,10], index=['b','c','a'])
  - sr1+sr2
- 如果两个Series对象的索引不完全相同，则结果的索引是两个操作数索引的并集。如果只有一个对象在某索引下有值，则结果中该索引的值为nan（缺失值）。

Series-数据对齐

- 例：
  - sr1 = pd.Series([12,23,34], index=['c','a','d'])
  - sr2 = pd.Series([11,20,10], index=['b','c','a'])
- 如何使结果在索引'b'处的值为11，在索引'd'处的值为34?
  - 灵活的算术方法：add, sub, div, mul
  - sr1.add(sr2, fill_value=0)

Series-缺失数据

- 缺失数据：使用NaN（Not a Number）来表示缺失数据。其值等于np.nan。内置的None值也会被当做NaN处理。
- 处理缺失数据的相关方法：
  - dropna()　过滤掉值为NaN的行
  - fillna()　填充缺失数据
  - isnull()　返回布尔数组，缺失值对应为True
  - notnull()　返回布尔数组，缺失值对应为False
- 过滤缺失数据：sr.dropna() 或 sr[data.notnull()]
- 填充缺失数据：fillna(0)

DataFrame-二维数据对象

- DataFrame是一个表格型的数据结构，含有一组有序的列。DataFrame可以被看做是由Series组成的字典，并且共用一个索引。
- 创建方式：
  - pd.DataFrame({'one':[1,2,3,4],'two':[4,3,2,1]})
  - pd.DataFrame({'one':pd.Series([1,2,3],index=['a','b','c']), 'two':pd.Series([1,2,3,4],index=['b','a','c','d'])})
  - ……
- csv文件读取与写入：
  - df.read_csv('filename.csv')
  - df.to_csv()

```
In [107]: pd.DataFrame({'one':pd.Series([1,2,3],index=['a','b','c']), 'two':pd.S
     ...: eries([1,2,3,4],index=['b','a','c','d'])})
Out[107]:
   one  two
a  1.0    2
b  2.0    1
c  3.0    3
d  NaN    4
```

DataFrame-常用属性

- index　　获取索引
- T　　转置
- columns　　获取列索引
- values　　获取值数组
- describe()　　获取快速统计

DataFrame-索引和切片

- DataFrame是一个二维数据类型，所以有行索引和列索引。
- DataFrame同样可以通过标签和位置两种方法进行索引和切片
- loc属性和iloc属性
  - 使用方法：逗号隔开，前面是行索引，后面是列索引
  - 行/列索引部分可以是常规索引、切片、布尔值索引、花式索引任意搭配

DataFrame-数据对齐与缺失数据

- DataFrame对象在运算时，同样会进行数据对齐，其行索引和列索引分别对齐。
- DataFrame处理缺失数据的相关方法：
  - dropna(axis=0,where='any',...)
  - fillna()
  - isnull()
  - notnull()

pandas-其他常用方法

- mean(axis=0,skipna=False)　　对列（行）求平均值
- sum(axis=1)　　对列（行）求和
- sort_index(axis, …, ascending)　　对列（行）索引排序
- sort_values(by, axis, ascending)　　按某一列（行）的值排序
- NumPy的通用函数同样适用于pandas

pandas-其他常用方法

- apply(func, axis=0)　将自定义函数应用在各行或者各列上，func可返回标量或者Series
- applymap(func)　将函数应用在DataFrame各个元素上
- map(func)　将函数应用在Series各个元素上

pandas-时间对象处理

- 时间序列类型：
  - 时间戳：特定时刻
  - 固定时期：如2017年7月
  - 时间间隔：起始时间–结束时间
- Python标准库处理时间对象：datetime
- 灵活处理时间对象：dateutil
  - dateutil.parser.parse()
- 成组处理时间对象：pandas
  - pd.to_datetime()

pandas-时间对象处理

- 产生时间对象数组：date_range
  - start　　开始时间
  - end　　结束时间
  - periods　　时间长度
  - freq　　时间频率，默认为'D'，可选H(our),W(eek),B(usiness),S(emi-)M(onth), (min)T(es), S(econd), A(year),…

pandas-时间序列

- 时间序列就是以时间对象为索引的Series或DataFrame。
- datetime对象作为索引时是存储在DatetimeIndex对象中的。
- 时间序列特殊功能：
  - 传入“年”或“年月”作为切片方式
  - 传入日期范围作为切片方式
  - 丰富的函数支持：resample(), strftime(), ……

pandas-文件处理

- 数据文件常用格式：csv（以某间隔符分割数据）
- pandas读取文件：从文件名、URL、文件对象中加载数据
  - read_csv　　默认分隔符为逗号
  - read_table　默认分隔符为制表符

pandas-文件处理

- read_csv、read_table函数主要参数：
  - sep　　指定分隔符，可用正则表达式如'\s+'
  - header=None　　指定文件无列名
  - name　　指定列名
  - index_col　　指定某列作为索引
  - skip_row　　指定跳过某些行
  - na_values　　指定某些字符串表示缺失值
  - parse_dates　　指定某些列是否被解析为日期，类型为布尔值或列表

pandas-文件处理

- 写入到csv文件：to_csv函数
- 写入文件函数的主要参数：
  - sep　　指定文件分隔符
  - na_rep　　指定缺失值转换的字符串，默认为空字符串
  - header=False　　不输出列名一行
  - index=False　　不输出行索引一列
  - cols　　指定输出的列，传入列表

pandas-文件处理

- pandas支持的其他文件类型：
  - json, XML, HTML, 数据库，pickle，excel...

Matplotlib

数据可视化工具包

Matplotlib-介绍

- Matplotlib是一个强大的Python绘图和数据可视化的工具包。
- 安装方法：pip install matplotlib
- 引用方法：import matplotlib.pyplot as plt
- 绘图函数：plt.plot()
- 显示图像：plt.show()

Matplotlib-plot函数

- plot函数：绘制点图或线图
  - 线型linestyle（–,–.,––,..）
  - 点型marker（v,^,s,*,H,+,x,D,o,…）
  - 颜色color（b,g,r,y,k,w,…）
- plot函数绘制多条曲线

Matplotlib-图像标注

- 设置图像标题：plt.title()
- 设置x轴名称：plt.xlabel()
- 设置y轴名称：plt.ylabel()
- 设置x轴范围：plt.xlim()
- 设置y轴范围：plt.ylim()
- 设置x轴刻度：plt.xticks()
- 设置y轴刻度：plt.yticks()
- 设置曲线图例：plt.legend()

Matplotlib-画布与图

- 画布：figure
  - fig = plt.figure()
- 图：subplot
  - ax1 = fig.add_subplot(2,2,1)
- 调节子图间距：
  - subplots_adjust(left, bottom, right, top, wspace, hspace)